



IR · PERTEMUAN 1 · TEKNIK KOMPUTER · SEMESTER 5

Pengantar Sistem Temu Kembali Informasi

Information Retrieval System — konsep dasar, arsitektur, dan ruang lingkup

Tujuan Pembelajaran Pertemuan 1

Sub-CPMK-1: Mahasiswa mampu menjelaskan definisi, ruang lingkup, dan arsitektur sistem temu kembali informasi, serta membedakannya dari sistem basis data konvensional. *(Ranah kognitif C2)*

1

Membedakan IR dan Data Retrieval

Ketepatan menguraikan perbedaan sifat kueri, hasil, dan kriteria keberhasilan pada kedua paradigma.

2

Menggambarkan Arsitektur Sistem

Kelengkapan diagram alur dari akuisisi dokumen hingga penyajian hasil terurut kepada pengguna.

3

Mengidentifikasi Fungsi Komponen

Ketepatan menjelaskan peran indexing, query processing, dan ranking beserta keterkaitannya.



LATAR BELAKANG

Masalah Besar: Ledakan Informasi

120ZB

Data Global 2026

Volume data dunia dalam zettabyte

500

Jam Video/Menit

Diunggah ke YouTube setiap menit

2.5J


Artikel Ilmiah/Tahun

Terbit di jurnal akademik global



Masalah IR bukan kekurangan data – melainkan kelebihan data. Cari "routing OLSR di MANET" di Google → 2 juta hasil, 90% tidak relevan. Tugas IR: ambil yang paling relevan dari yang banyak.

Apa Itu Sistem Temu Kembali Informasi?



Definisi

Sistem yang menerima **kebutuhan informasi** dari pengguna dalam bentuk **query**, lalu mencari dan mengembalikan dokumen yang **relevan** dari sekumpulan koleksi.

Rumus Sederhana

Query + Koleksi Dokumen → Sistem IR → Dokumen Terurut berdasarkan Relevansi

Contoh Nyata

Query: "*hp gaming 3 juta*" → dari 10.000 produk Tokopedia → IR mengembalikan 20 HP paling relevan, **diurutkan**.

📌 IR fokus pada **relevansi**, bukan kebenaran mutlak.

IR vs Database: Apa Bedanya?

Aspek	Database	Sistem Temu Kembali
Data	Terstruktur (Tabel)	Tidak terstruktur (Teks, Gambar)
Query	Pasti: <code>SELECT * WHERE harga=3000000</code>	Kabur: <i>"hp gaming murah"</i>
Hasil	Semua atau tidak sama sekali	Peringkat: paling relevan di atas
Tujuan	Akurasi 100%	Relevansi terbaik
Algoritma	Logika pasti	Statistik & probabilitas

Contoh Database

Cari NIM 20231001 → pasti ketemu **1 data** mahasiswa.

Contoh IR

Cari *"dosen yang ahli AI"* → bisa keluar **10 dosen**, diurutkan berdasarkan publikasi.

Batas Cakupan Kajian

Apa yang termasuk dan apa yang berada di luar bahasan mata kuliah ini

✓ Termasuk Cakupan

- Pencarian dokumen teks pada koleksi besar
- Perankingan hasil menurut dugaan relevansi
- Klasifikasi dan klasterisasi dokumen
- Analisis tautan dan pencarian skala web
- Evaluasi kinerja sistem pencarian
- Representasi semantik dan pencarian vektor

✗ Di Luar Cakupan

- Kueri terstruktur SQL atas basis data relasional
- Transaksi, integritas, dan pemulihan data
- Perancangan skema dan normalisasi tabel
- Kompilasi bahasa dan sintaksis pemrograman
- Penambangan data numerik murni tanpa unsur teks
- Pelatihan model bahasa besar dari awal

Temu Kembali Informasi vs Temu Kembali Data

Dua paradigma dengan asumsi keberhasilan yang berbeda

Aspek	Temu Kembali Data (SQL)	Temu Kembali Informasi
Objek yang dicari	Rekaman terstruktur berskema baku	Dokumen tak terstruktur, umumnya teks
Bentuk permintaan	Kueri formal, semantiknya tunggal	Kueri bahasa alami, sering ambigu
Model pencocokan	Pencocokan tepat atas nilai atribut	Pencocokan sebagian berbasis kemiripan
Bentuk keluaran	Himpunan hasil, tanpa urutan penting	Daftar terurut menurut dugaan relevansi
Ukuran keberhasilan	Benar atau salah secara deterministik	Presisi, recall, dan kepuasan pengguna
Dampak kesalahan	Hasil dapat gagal sepenuhnya	Kualitas menurun secara berangsur

📌 Keduanya saling melengkapi. Mesin pencari modern lazim menggabungkan penyaringan terstruktur pada metadata dengan perankingan berbasis kemiripan pada isi dokumen.

Arsitektur Umum Sistem IR



Dokumen & Prabersih

Pengindeksan

Proses Query & Pencocokan

Peringkat & Hasil

Saat Anda mengetik di Google, dalam **0,2 detik** sistem tidak membaca semua website – melainkan membuka **Inverted Index** yang sudah dibangun sebelumnya, lalu menghitung skor kemiripan query vs dokumen.

Arsitektur Sistem Temu Kembali

Dua jalur kerja yang bertemu pada satu struktur data



Pemisahan ini adalah keputusan rekayasa yang menentukan: seluruh pekerjaan mahal dipindahkan ke jalur **luring**, sehingga jalur **daring** cukup membaca indeks dan menghitung skor – memungkinkan waktu respons di bawah 0,3 detik.

Rincian Jalur Luring

Tiga tahap yang menyiapkan koleksi agar siap dicari



A — Akuisisi & Penyaringan

Mengumpulkan dokumen via perayapan web atau konektor internal, mengekstraksi teks dari beragam format, dan membuang duplikat.

→ *Pertemuan 11*



B — Pra-pemrosesan Teks

Tokenisasi, normalisasi, pembuangan kata henti, dan stemming agar variasi permukaan tidak menghalangi pencocokan.

→ *Pertemuan 2*



C — Pembangunan & Kompresi Indeks

Membalik hubungan dokumen-term menjadi term-dokumen, menyusun postings list, lalu memampatkannya agar cepat dibaca.

→ *Pertemuan 3*

Sekilas Isi Indeks Terbalik

Contoh kecil yang akan dibangun sendiri pada Pertemuan 3

Koleksi Dokumen

```
D1  sistem temu kembali informasi
D2  sistem basis data
D3  temu kembali informasi web
```

Indeks Terbalik yang Terbentuk

```
sistem    → D1, D2
temu      → D1, D3
kembali   → D1, D3
informasi → D1, D3
basis     → D2
data      → D2
web       → D3
```

Menjawab Kueri "temu AND informasi"

```
postings(temu)      = { D1, D3 }
postings(informasi) = { D1, D3 }
irisan kedua daftar = { D1, D3 }
                    ← jawaban
```

📄 Sistem tidak pernah menyentuh isi dokumen saat kueri dijalankan. Yang dibaca hanya dua daftar pendek, lalu diiris. Inilah kunci efisiensi indeks terbalik.

Rincian Jalur Daring

Empat tahap yang dijalankan dalam hitungan milidetik

1

Pemrosesan Kueri

Kueri melewati pra-pemrosesan yang sama dengan dokumen, ditambah koreksi ejaan, penanganan frasa, dan perluasan kueri.

Pertemuan 4 & 10

2

Pengambilan Kandidat

Postings list untuk setiap term diambil dari indeks, lalu dipangkas menjadi himpunan kandidat yang jauh lebih kecil.

Pertemuan 3 & 6

3

Perhitungan Skor & Perankingan

Setiap kandidat diberi skor kemiripan terhadap kueri, kemudian diurutkan. Di sinilah model perankingan bekerja.

Pertemuan 5, 6, 9, 14

4

Penyajian & Perekaman

Hasil ditampilkan bersama cuplikan teks, sementara interaksi pengguna direkam sebagai bahan evaluasi dan perbaikan.

Pertemuan 7 & 15

Enam Komponen Utama Sistem IR

1

Koleksi Dokumen

Semua data sumber: jurnal, web, PDF

2

Preprocessing

Bersihkan teks: "*Lari, berlari, pelari*" → "**lari**"

3

Indexing

Buat "indeks buku" agar tidak baca satu per satu

4

Query Processing

Ubah query alami menjadi kata kunci terstruktur

5

Matching & Ranking

Hitung skor kemiripan query vs dokumen

6

Hasil

Tampilkan top-N dokumen paling relevan

IR dalam Kehidupan Nyata




Web Search Engine

Google, Bing, DuckDuckGo –
miliaran query per hari



E-Commerce & Enterprise

Rekomendasi produk
Shopee/Tokopedia, pencarian
dokumen internal di UNM



Chatbot RAG & Agentic AI

ChatGPT mencari data dari PDF
dulu, lalu menjawab – IR + AI
bekerja bersama



Digital Library

Garuda Ristek, Google Scholar –
cari skripsi, jurnal, dan publikasi
ilmiah

Tantangan Era AI & Arah Mata Kuliah

Tantangan Modern

- **Semantic Gap** – "mobil cepat" ≠ "Ferrari"
- **Bahasa Alami** – query panjang dan ambigu
- **Multimedia & Personalisasi** – hasil berbeda per pengguna

3 Hal Penting Hari Ini

1. IR = ilmu mencari informasi yang **relevan**
2. Beda dengan DB: hasilnya **peringkat**, bukan pasti
3. Komponen utama: **Indexing, Query, Ranking**

15 Minggu ke Depan

VSM, BM25, Indexing, Evaluasi → bangun **Search Engine sendiri**

📄 **PRAKTIKUM 1**