



Sistem Temu Kembali Informasi

Pertemuan 3: Evaluasi Sistem Temu Kembali

"Mesin pencariimu bagus – menurut siapa?"

Pada Pertemuan 2 kita berhasil memberi skor dan peringkat. Sekarang muncul pertanyaan yang jauh lebih sulit: bagaimana **membuktikan** bahwa peringkat itu benar? Kita akan membedah **Precision, Recall, F1, dan MAP** – alat ukur yang dipakai Google, Tokopedia, dan setiap peneliti temu kembali informasi.

Capaian Pembelajaran

Setelah menyelesaikan pertemuan ini, mahasiswa mampu **mengukur dan membandingkan kualitas sistem temu kembali secara kuantitatif**, bukan berdasarkan kesan.

1

Ground Truth

Menjelaskan konsep relevance judgment dan menyusun kunci jawaban untuk sebuah koleksi uji.

2

Precision & Recall

Menghitung akurasi dan kelengkapan hasil, serta menjelaskan pertukaran di antara keduanya.

3

F1 dan MAP

Menggabungkan dua metrik menjadi satu angka, dan mengukur mutu peringkat dengan Average Precision.

4

Praktikum Python

Mengevaluasi mesin pencari lagu dari Praktikum 2 menggunakan kode evaluasi sendiri di Google Colab.



Review: Masalah dari Pertemuan 2

Di Pertemuan 2 kita berhasil membangun mesin pencari yang memberi skor dan mengurutkan hasil. Masalahnya **berpindah**, bukan hilang.

Skenario Nyata

Dua kelompok membangun mesin pencari lagu dengan kueri "cinta patah hati". Kelompok A menaruh lagu X di peringkat satu; Kelompok B menaruh lagu Y. **Kelompok mana yang mesinnya lebih baik, dan atas dasar apa?**

Akar Masalahnya

Cosine similarity hanya memberi tahu dokumen mana yang *mirip* dengan kueri – bukan yang benar-benar berguna. Skor 0,87 dihasilkan sistem itu sendiri, seperti mahasiswa yang menilai ujiannya sendiri.

- ❏ Kita membutuhkan penilai dari luar sistem: kunci jawaban buatan manusia.

Fondasi Evaluasi: Ground Truth

Ground truth (relevance judgment) adalah daftar dokumen yang dinyatakan relevan oleh manusia untuk sebuah kueri — disusun *sebelum* sistem diuji, dan menjadi acuan pembandingan. Dalam penelitian, daftar ini disebut **qrels**.

Analogi: Kunci Jawaban Ujian

- Dosen menyusun kunci jawaban lebih dahulu, bukan setelah melihat jawaban mahasiswa.
- Jawaban mahasiswa dibandingkan dengan kunci, bukan dengan jawaban mahasiswa lain.
- Tanpa kunci, semua jawaban tampak sama benarnya.

Contoh: Koleksi Sepuluh Lagu

Kueri: "**cinta patah hati**"

Relevan (4 lagu): L2 · L3 · L5 · L9

Tidak Relevan (6 lagu): L1 · L4 · L6 · L7 · L8 · L10

Koleksi ini dipakai sebagai contoh berjalan sampai akhir pertemuan.

Empat Kemungkinan Hasil Pencarian

Analogi **menjaring ikan**: apa yang masuk jaring, dan apa yang lolos?

	Dikembalikan Sistem	Tidak Dikembalikan
Relevan	True Positive – Ikan yang berhasil masuk jaring. Dokumen relevan yang ditemukan.	False Negative – Ikan yang lolos dari jaring. Dokumen relevan yang terlewat.
Tidak Relevan	False Positive – Sampah yang ikut terjaring. Dokumen tidak relevan yang muncul.	True Negative – Air yang memang tidak dijaring. Hampir tidak pernah dipakai dalam IR.

Precision menghukum False Positive

Seberapa bersih isi jaring Anda?

Recall menghukum False Negative

Seberapa banyak ikan yang tidak lolos?

Precision & Recall: Definisi dan Contoh

Precision

Berapa persen dari dokumen yang dikembalikan yang benar-benar relevan?

$$\text{Precision} = \frac{\text{Relevan ditemukan}}{\text{Total dikembalikan}}$$

Contoh hasil 5 lagu teratas (L2✓, L7X, L3✓, L1X, L5✓):

$$\text{Precision@5} = 3 \div 5 = 0,60$$

Recall

Berapa persen dari seluruh dokumen relevan di koleksi yang berhasil ditemukan?

$$\text{Recall} = \frac{\text{Relevan ditemukan}}{\text{Total relevan di koleksi}}$$

Dari 4 lagu relevan (L2, L3, L5, L9), hanya 3 yang masuk lima teratas – L9 terlewat.

$$\text{Recall} = 3 \div 4 = 0,75$$

Recall kritis untuk: pencarian paten, pustaka skripsi, rekam medis.



Pertukaran Precision dan Recall

Menaikkan satu metrik **hampir selalu menurunkan** metrik yang lain. Dua strategi ekstrem dengan koleksi yang sama (4 relevan dari 10 dokumen):

Strategi Pelit

Hanya mengembalikan 3 dokumen paling diyakini benar — ketiganya relevan.

$$\text{Precision} = 1,00 \cdot \text{Recall} = 0,75$$

Sempurna bersih, tetapi satu lagu relevan tetap terlewat.

Strategi Rakus

Mengembalikan seluruh 10 dokumen tanpa menyaring apa pun.

$$\text{Precision} = 0,40 \cdot \text{Recall} = 1,00$$

Tidak ada yang terlewat, tetapi pengguna harus menyaring sendiri enam sampah.



Google

Mengejar Precision — pengguna hanya melihat halaman pertama.



Pencarian Paten

Mengejar Recall — melewatkan satu dokumen berarti gugatan hukum.



Kebanyakan Sistem

Mencari titik tengah — membutuhkan satu angka yang mewakili keduanya.

F1-Score: Satu Angka untuk Dua Metrik

F1-Score adalah **rata-rata harmonik** dari Precision dan Recall. Nilainya hanya tinggi apabila *kedua* metrik sama-sama tinggi.

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Mengapa Bukan Rata-rata Biasa?

Sistem sangat pelit: hanya mengembalikan 1 dokumen, dan dokumen itu benar.

Metrik	Nilai
Precision	1,00
Recall	0,10
Rata-rata biasa	0,55
F1-Score	0,18

Rata-rata biasa menutupi kelemahan; F1 menolak berkompromi.

Perhitungan pada Contoh Kita

Precision = 0,60 · Recall = 0,75

$$F1 = \frac{2 \times (0,60 \times 0,75)}{0,60 + 0,75} = \frac{0,90}{1,35} = 0,667$$

Terletak di antara 0,60 dan 0,75, condong ke nilai yang lebih rendah.

📌 F1 tidak bisa dibohongi oleh satu metrik yang tinggi.

Masalah Baru: Urutan Diabaikan

Precision, Recall, dan F1 memperlakukan hasil sebagai **himpunan**, bukan sebagai peringkat. Dua mesin berikut mengembalikan lima dokumen dengan tiga dokumen relevan yang sama – hanya urutannya berbeda.

Mesin A – Yang Bagus di Atas

- 1. Relevan ✓
- 2. Relevan ✓
- 3. Relevan ✓
- 4. Tidak relevan ✗
- 5. Tidak relevan ✗

Mesin B – Yang Bagus Terkubur

- 1. Tidak relevan ✗
- 2. Tidak relevan ✗
- 3. Relevan ✓
- 4. Relevan ✓
- 5. Relevan ✓

Metrik	Mesin A	Mesin B	Sama?
Precision@5	0,60	0,60	✓ Sama
Recall	1,00	1,00	✓ Sama
F1-Score	0,75	0,75	✓ Sama

Ketiga metrik menyatakan kedua mesin sama baiknya – padahal setiap pengguna jelas lebih memilih Mesin A. **Kita membutuhkan metrik yang peduli pada urutan.**

Precision@K & Average Precision

Precision@K

Hanya menilai K dokumen teratas – sesuai banyaknya hasil yang benar-benar dilihat pengguna. Nilai K lazim: **K=1** (asisten suara), **K=10** (mesin pencari web), **K=20** (marketplace).

Peringkat: L2✓ L7✗ L3✓ L1✗ L5✓

- **Precision@1** = $1 \div 1 = 1,00$
- **Precision@3** = $2 \div 3 = 0,67$
- **Precision@5** = $3 \div 5 = 0,60$

Average Precision (AP)

Hitung Precision setiap kali dokumen relevan ditemukan, lalu rata-ratakan. Pembagi = total relevan di koleksi.

Pos	Dok	P di titik ini
1	L2 ✓	1,000
2	L7 ✗	—
3	L3 ✓	0,667
4	L1 ✗	—
5	L5 ✓	0,600

$$AP = (1,000 + 0,667 + 0,600) \div 4 = 0,567$$

Pembagi 4 karena L9 yang relevan tidak pernah ditemukan.

AP membedakan Mesin A (AP=1,000) vs Mesin B (AP=0,478) – selisih 0,522 yang tidak tertangkap oleh Precision maupun Recall.

MAP: Menilai Sistem, Bukan Satu Kueri

Mean Average Precision (MAP) adalah rata-rata AP atas banyak kueri uji. Sebuah sistem bisa kebetulan sangat baik pada satu kueri dan buruk pada kueri lain – menilai dengan satu kueri seperti menilai mahasiswa dari satu soal ujian.

$$\text{MAP} = \frac{\text{Jumlah seluruh AP}}{\text{Banyaknya kueri uji}}$$

Contoh: Tiga Kueri Uji

Kueri	AP
Q1 "cinta patah hati"	0,567
Q2 "rindu"	0,750
Q3 "bahagia"	0,333

$$\text{MAP} = (0,567 + 0,750 + 0,333) \div 3 = 0,550$$

Standar dalam Penelitian

- Koleksi uji standar seperti **TREC** menyediakan puluhan hingga ratusan kueri.
- MAP menjadi angka tunggal yang dilaporkan dalam publikasi ilmiah.
- Dua sistem dapat dibandingkan langsung melalui angka ini.

📌 MAP = satu angka yang mewakili mutu sistem secara keseluruhan.

Perbandingan Lengkap: Kapan Memakai Metrik yang Mana

Metrik	Yang Diukur	Peduli Urutan?	Paling Cocok Untuk
Precision	Kebersihan hasil	Tidak	Mesin pencari umum, marketplace
Recall	Kelengkapan hasil	Tidak	Paten, hukum, rekam medis
F1-Score	Keseimbangan keduanya	Tidak	Perbandingan sistem secara ringkas
Precision@K	Mutu K teratas	Sebagian	Halaman pertama hasil pencarian
Average Precision	Mutu peringkat satu kueri	Ya	Analisis mendalam per kueri
MAP	Mutu sistem keseluruhan	Ya	Publikasi ilmiah, tolok ukur TREC

📌 Kaidah praktis: laporkan **Precision@10** untuk menggambarkan pengalaman pengguna, dan **MAP** untuk membandingkan sistem secara ilmiah. Satu metrik saja tidak pernah cukup.

Praktikum 3: Menilai Mesin Pencari Buatan Sendiri

Spesifikasi Tugas

- **Bahan:** mesin pencari lagu dari Praktikum 2
- **Ground truth:** tandai sendiri lagu mana yang relevan untuk tiap kueri
- **Kueri uji:** tiga kueri berbeda
- **Luaran:** Precision@5, Recall, F1, AP, dan MAP
- **Perangkat:** Google Colab · **Waktu:** 25 menit

Kode Inti

```
relevan = {2, 3, 5, 9}
hasil = [2, 7, 3, 1, 5]

def precision_at_k(hasil, relevan, k):
    return sum(1 for d in hasil[:k]
               if d in relevan) / k

def recall(hasil, relevan):
    cocok = sum(1 for d in hasil
                 if d in relevan)
    return cocok / len(relevan)

def f1(p, r):
    return 0.0 if p+r==0 else 2*p*r/(p+r)

def average_precision(hasil, relevan):
    hit, total = 0, 0.0
    for i, d in enumerate(hasil, start=1):
        if d in relevan:
            hit += 1
            total += hit / i
    return total / len(relevan)

p = precision_at_k(hasil, relevan, 5)
r = recall(hasil, relevan)
print(p, r, f1(p,r),
      average_precision(hasil, relevan))
# 0.6 0.75 0.6667 0.5667
```




Koneksi ke Dunia Nyata

Metrik ini bukan sekadar bahan ujian — **keputusan bisnis bernilai miliaran rupiah** bersandar pada angka-angka ini.

Google & Uji A/B

Setiap perubahan algoritma diuji pada sebagian kecil pengguna. Metrik peringkat dibandingkan sebelum diterapkan ke seluruh dunia.

Tokopedia & Shopee

Precision@10 dipantau terus-menerus. Bila produk di layar pertama tidak relevan, pembeli pergi dan pendapatan langsung turun.

TREC & Kaggle

Peserta diberi koleksi dan ground truth yang sama, lalu peringkat berdasarkan MAP. Pemenang ditentukan oleh angka, bukan pendapat.

Netflix

Metrik peringkat menentukan judul mana yang tampil di baris teratas. Salah menaruh judul berarti pelanggan berhenti berlangganan.

Rangkuman & Preview Pertemuan 4

Ground Truth

Kunci jawaban buatan manusia. Tanpa ini, tidak ada satu pun metrik yang bisa dihitung.

Precision & Recall

Kebersihan dan kelengkapan hasil. Keduanya saling bertukar – menaikkan satu menurunkan yang lain.

F1-Score

Rata-rata harmonik yang condong ke nilai terkecil – tidak bisa dibohongi oleh satu metrik yang tinggi.

Precision@K & AP

Metrik yang peduli pada posisi. Dokumen relevan di peringkat satu bernilai jauh lebih besar daripada di peringkat lima.

MAP

Rata-rata AP atas banyak kueri – satu angka yang mewakili mutu sistem secara keseluruhan.

"Yang tidak diukur tidak bisa diperbaiki. Mesin pencari yang baik bukan yang *terasa* bagus, melainkan yang **terbukti** bagus melalui angka."

Tugas Rumah

Gunakan 10 judul skripsi dari Pertemuan 2. Susun ground truth untuk kueri "AI", "Jaringan", dan "IoT". Hitung Precision@3, Recall, F1, AP, dan MAP. Tulis analisis 5 kalimat: kueri mana yang paling buruk dan mengapa. Kumpulkan via LMS dalam format `.ipynb` atau PDF.

Preview Pertemuan 4

1. **Pra-pemrosesan Lanjutan** – stopwords removal, stemming Bahasa Indonesia dengan Sastrawi.
2. **Eksansi Kueri** – sinonim otomatis agar "hp" menemukan "handphone".
3. **Umpan Balik Relevansi** – memanfaatkan perilaku pengguna untuk memperbaiki kueri.

📄 Bawa nilai MAP hari ini – pada Pertemuan 4 kita hitung ulang setelah perbaikan!